IUM - Dokumentacja wstępna projektu

Michał Pędziwiatr, Kacper Siemionek

Treść zadania

“Czasami oferenci zawyżają ceny, aby nikt w danym okresie nie rezerwował u nich noclegów – jakoś musimy to wykrywać, żeby dało się odpowiednio reagować.”

Kontekst

W ramach projektu wcielamy się w rolę analityka pracującego dla portalu Nocarz – serwisu, w którym klienci mogą wyszukać i dokonać rezerwacji noclegu (zapewnianego przez oferentów). Praca na tym stanowisku nie jest łatwa – zadanie dostajemy w formie enigmatycznego opisu i to do nas należy doprecyzowanie szczegółów tak, aby dało się je zrealizować. To oczywiście wymaga zrozumienia problemu, przeanalizowania danych, czasami negocjacji z szefostwem. Poza tym, oprócz przeanalizowania zagadnienia i wytrenowania modeli, musimy przygotować je do wdrożenia produkcyjnego –zakładając, że w przyszłości będą pojawiać się kolejne ich wersje, z którymi będziemy eksperymentować Jak każda szanująca się firma internetowa,

Nocarz zbiera dane dotyczące swojej działalności – są to (analitycy mogą wnioskować o dostęp do tych informacji na potrzeby realizacji zadania):

- szczegółowe dane o dostępnych lokalach,
- recenzje lokali,
- kalendarz z dostępnością i cenami,
- baza klientów i sesji.

Problem biznesowy

Opis problemu

Właściciele lokali wynajmujący je na portalu “Nocarz” mają tendencje do nieformalnej blokady dostępności oferty, poprzez sztuczne zawyżanie ich cen. Ustawiają nierealistycznie wysoką cenę lokalu, aby utrzymać jego widoczność na portalu, jednocześnie minimalizując ryzyko rezerwacji.

Zjawisko to doprowadza do sytuacji, w której znaczna część ofert na stronie, może być “ofertami widmo”. Wpływa to negatywnie na UX portalu, ponieważ użytkownicy zasypywani są nieatrakcyjnymi ofertami. Może to także skutkować zaburzeniem statystyk platformy.

Cel biznesowy

Głównym celem jest wykrywanie i identyfikowanie wcześniej wspomnianych przypadków celowego zawyżania cen, co pozwoli na przywrócenie konkurencyjności i uczciwości ofert oraz przełoży się na zwiększenie zaufania klientów, wzrost liczby rezerwacji i przychodów portalu.

Wdrożenie modelu umożliwi odpowiednie reagowanie na niepożądane zachowania oferentów:

- **Wprowadzenie mechanizmu weryfikacji cen**: automatyczne flagowanie podejrzanych ofert, co umożliwia interwencję ze strony administratorów lub automatyczną, zanim oferta zaszkodzi portalowi.
- **Automatyczne ostrzeżenia oferentów**: powiadomienia wysyłane do oferentów, u których wykryto celowe zawyżanie cen, służy jako forma zachęcenia do zmiany postępowania na portalu.
- **Zarządzanie widocznością ofert**: mechanizm regulacyjny, zawyżona cena może skutkować obniżeniem widoczności oferty w wynikach wyszukiwania lub w proponowanych ofertach.

Biznesowe kryterium sukcesu

Biznesowe kryterium sukcesu bada realny wpływ wdrożonego systemu na zachowanie oferentów i efektywności portalu Nocarz.

Proponowanym miernikiem spełnienia kryterium są **eksperymenty A/B** - przed zastosowaniem modelu, system losowo podzieli wszystkie oferty na grupę kontrolną i eksperymentalną. Grupa kontrolna odzwierciedla początkowy stan portalu, bez interwencji w przypadku podejrzanie wysokich cen. Natomiast grupa eksperymentalna będzie testowała wprowadzony mechanizm, oferty będą przetwarzane przez model, celowo zawyżone ceny spowodują interwencję.

W ramach eksperymentu, przeprowadzanego raz w miesiącu, mierzone będą:

- **Skuteczność interwencji**: procent przypadków, w których oferent po otrzymaniu ostrzeżenia zastosował się do wytycznych i obniżył cenę.
- **Wzrost liczby rezerwacji**: umożliwia porównanie, czy zawyżone ceny miały realny wpływ na liczbę rezerwacji.
- **Skargi oferentów**: sprawdzenie, czy po zastosowaniu wymienionych mechanizmów oferenci składają skargi lub usuwają konta.

Model zostanie uznany za skuteczny, jeśli w grupie eksperymentalnej w porównaniu do kontrolnej:

- **Skuteczność interwencji** wyniesie 25% - co najmniej ¼ powiadomionych oferentów zdecyduje się na korektę ceny.
- **Liczba rezerwacji** wzrośnie o minimum 3% w skali miesiąca - wyeliminowanie zawyżonych ofert przełoży się na wzrost zainteresowania ofertami, tym samym wzrostem liczby rezerwacji.

- **Liczba skarg i usuniętych kont przez oferentów** nie wzrośnie o więcej niż 1 p.p. - przekroczenie tego progu oznacza wykrywanie zbyt wielu “fałszywych alarmów”.

Zadanie modelowania

Cel modelowania

Celem zadania jest stworzenie mechanizmu klasyfikacyjnego, który dla każdego lokalu i określonego okresu czasowego (np. tydzień) oceni prawdopodobieństwo, że jego cena jest celowo zawyżona, co wymaga to wcześniejszego zdefiniowania, czym konkretnie objawia się wspomniany problem. Zadanie zostanie zaimplementowane jako **klasyfikacja binarna:**

- klasa 1 dla cen celowo zawyżonych
- klasa 0 dla uczciwych ofert

Obiektem klasyfikacji jest wektor cech zagregowanych dla danego lokalu i przedziału czasowego.

Modele

Zadanie zostanie porównane przy wykorzystaniu dwóch różnych podejść:

- **Model bazowy**: ustala minimalną granicę jakości, np. regresja logistyczna, naiwny klasyfikator bayesowski. Model prosty do wdrożenia, służy jedynie jako punkt odniesienia do oceny modelu docelowego.
- **Model docelowy**: celem jest osiągnięcie wyników lepszych od modelu bazowego oraz takich, które zadowolą klienta.

Analityczne kryterium sukcesu

Celem jest zdefiniowanie wskaźników, które pozwolą na weryfikację jakości modelu na etapie eksperymentów przed podjęciem decyzji o wdrożeniu, korzystając ze zbiorów testowych. Punktem odniesienia do zbadania jakości modelu docelowego będzie dokładność modelu bazowego.

Poza samą dokładnością, do oceny modelu wykorzystamy miary oparte na macierzy/tablicy pomyłek, poświęcając uwagę kosztownym błędom:

- ***True Positive***: słuszne wykrycie zawyżonej ceny
- ***False Positive***: uczciwa cena została wykryta jako zawyżona
- ***False Negative***: zawyżona cena nie została wykryta

Precyzja (*precision*): weryfikuje, jak często model ma rację co do zawyżonej ceny. Zwiększona precyzja zapewnia unikanie niesłusznych interwencji na uczciwych oferentach.

Czułość (*recall*): weryfikuje, ile przypadków zawyżonych cen udało się wykryć. Wyższa czułość oznacza więcej wykrytych przypadków zawyżonych cen.

Model zostanie uznany za skuteczny, gdy:

- Osiągnie wyniki lepsze o 10 p.p. od **modelu bazowego.**
- **Precyzja** wyniesie 80% lub więcej - ⅘ wysłanych ostrzeżeń trafią do faktycznych oszustów.
- **Czułość** wyniesie 65% lub więcej - model wykryje ponad połowę rzeczywistych przypadków zawyżenia cen.

Analiza Danych

Opis danych

Kalendarz (*calendar.csv*)
Kluczowy zbiór w kontekście naszego zadania, zawiera historię cen i dostępności wszystkich lokali, którą możemy zestawić z ceną w aktualnej ofercie.

Oferty (*listings.csv*)
Opisuje dostępne na portalu lokale i ich kluczowe cechy, tj. cena, lokalizacja, wyposażenie, ocena jakości.

Sesje (*sessions.csv*)
Informacje dotyczące popytu na konkretne oferty, pozwalają zweryfikować, czy rynek akceptuje cenę ustawioną przez oferenta.

Recenzje (*reviews.csv*)
Zbiór wszystkich recenzji z portalu. Mogą pomóc w uzasadnieniu wysokiej ceny, która niekoniecznie musi kwalifikować się do naszego problemu.

Użytkownicy (*users.csv*)
Baza użytkowników.

Weryfikacja danych - zbiór v0

Statystyki dotyczące ceny:

Średnia	Wartość minimalna	Wartość maksymalna	Odchylenie standardowe
152.32	10.00	9999.00	387.97

Uwagę zwraca wysoka wartość odchylenia, która jest ponad dwukrotnie większa od średniej, co świadczy o sporej zmienności danych.

Wykres obejmuje pełen zakres cen, z których większość koncentruje się w wąskim przedziale bliskim 0. Rozkład rozciąga się aż do 9999 USD, co potwierdza obecność wartości odstających w wyższych przedziałach cenowych (widoczne są małe skoki na wykresie).

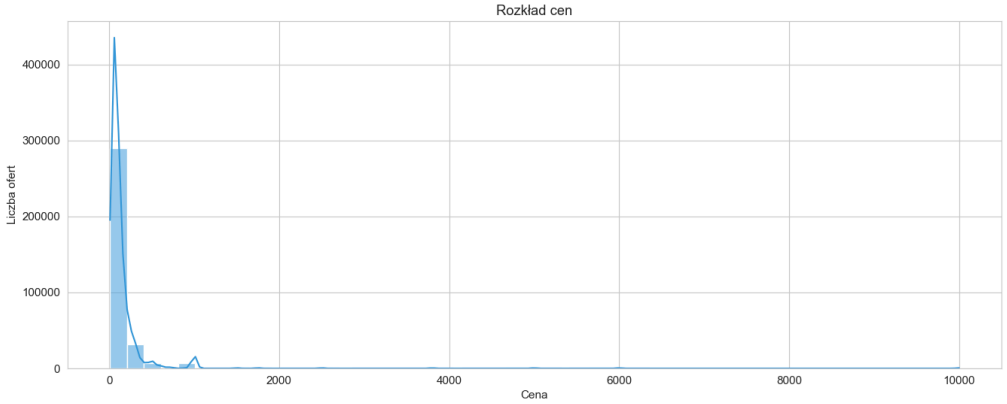

Wraz ze wzrostem cen zainteresowanie nie spada do zera, oferta z najwyższą ceną wciąż osiąga ponad 30 interakcji, co może nie jest najwyższą wartością, jednak nadal przewyższa sporą część ofert z zakresu 0-1000 USD.

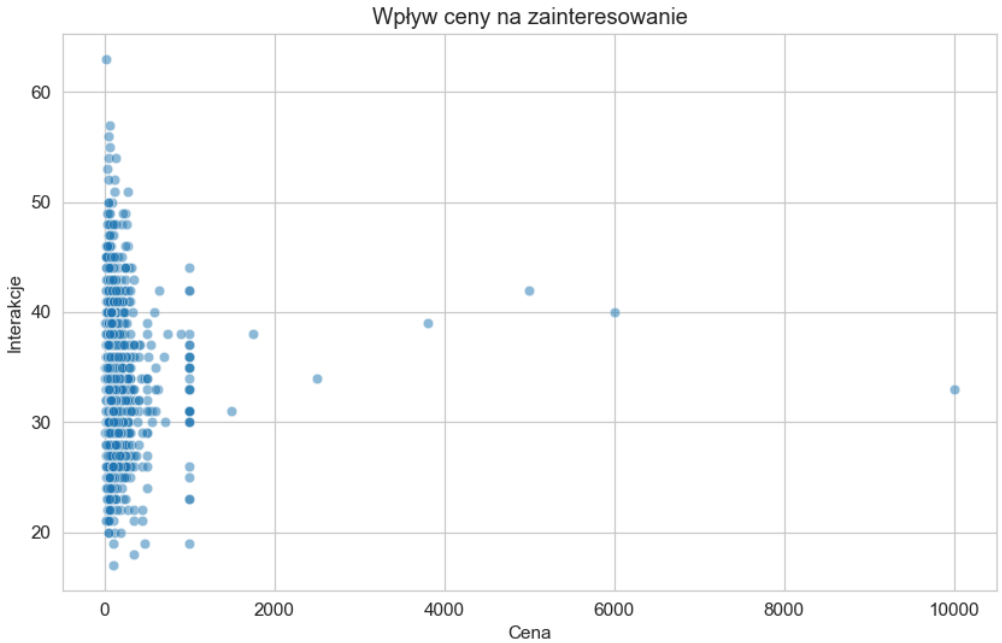

Najwyższą medianę cen osiągają oferty pokoi hotelowych, najniższą pokoje współdzielone.

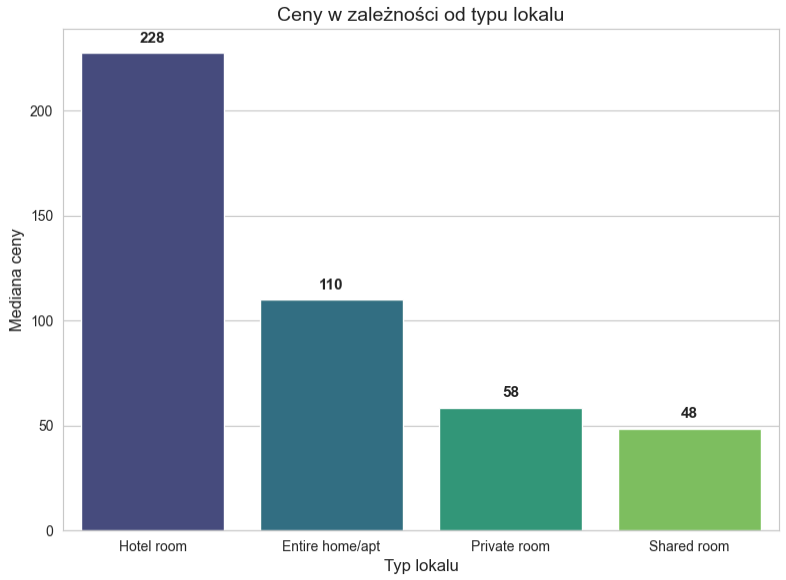

Na wykresie przedstawiono 10 najdroższych dzielnic sortując po wartości mediany cen. Jednak najdroższe dzielnice znajdują się tu ze względu na fakt, że posiadają mało ofert, co zawyża medianę. Przykładowo w pierwszej najdroższej dzielnicy została wystawiona jedna oferta z prawdopodobnie zawyżoną ceną - stąd mediana równa 3800 USD.

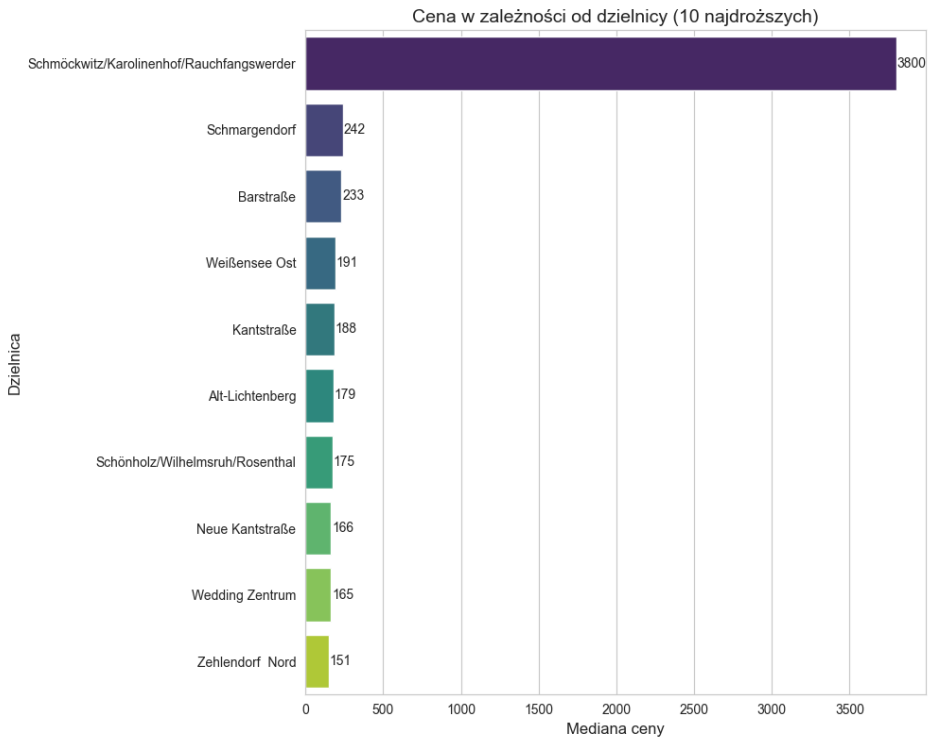

Tym razem przefiltrowano dzielnice, na wykresie znajdują się tylko te, które mają przynajmniej 10 ofert.

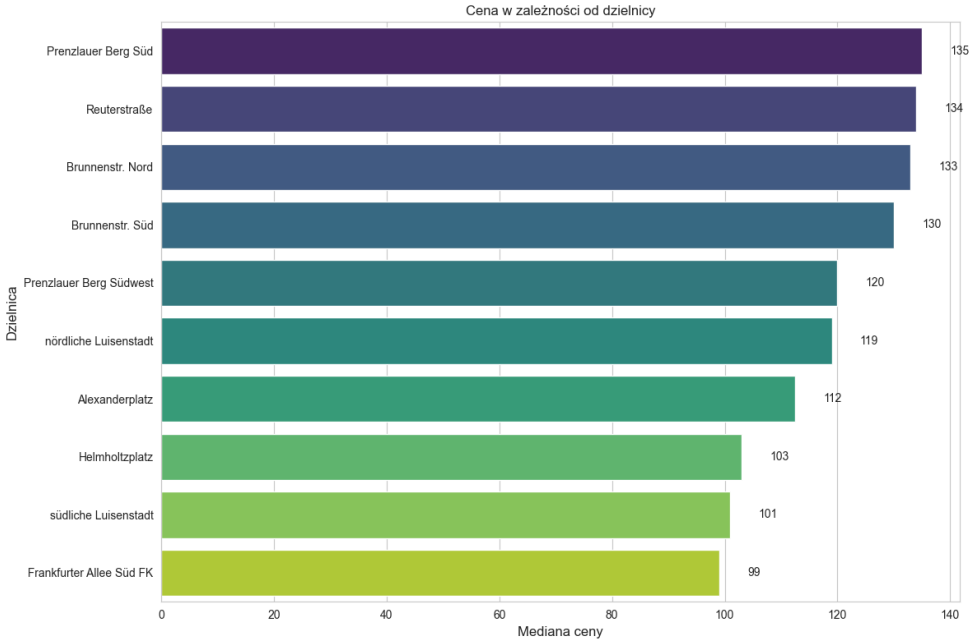

Najmniejszą dostępność notowana jest w okresie październik-styczeń, osiąga około 25%. W pozostałych miesiącach utrzymuje się w okolicach 30-35%.

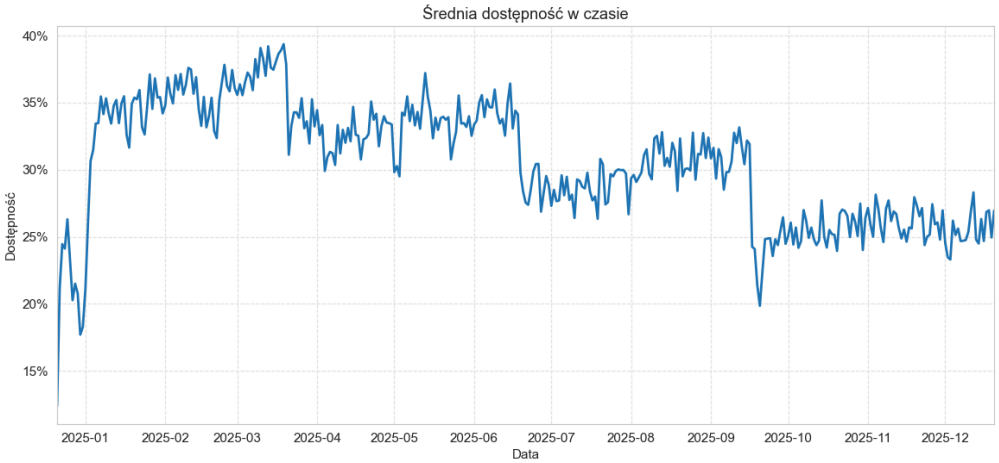

Na potrzeby zbadania, czy zmienne wejściowe niosą informację o zmiennej wyjściowej, ustalono, że podejrzane oferty to 2% ofert z najwyższymi cenami i małą liczbą recenzji.

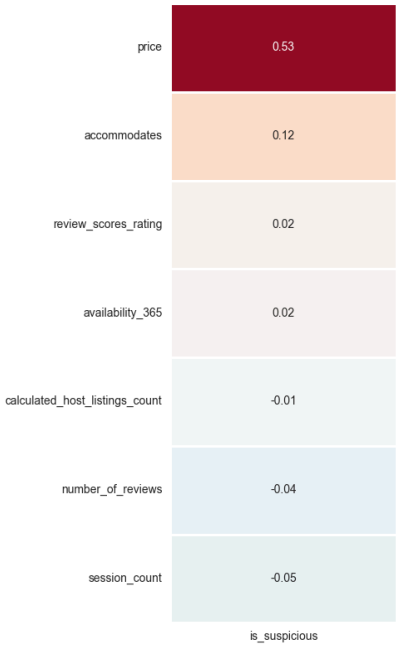

- Z naszego założenia wprost wynika, że wysoka cena oznacza podejrzaną ofertę, dlatego korelacja z **ceną** jest wysoka i dodatnia.
- Dodatnią korelację posiada również wskaźnik **pojemności** - prawdopodobnie niektóre drogie oferty odpowiadają dużym obiektom.
- Podejrzane oferty mają również tendencję do wysokiej **dostępności** na przestrzeni roku.
- Ujemna korelacja z **interakcjami** wskazuje na to, że zawyżone ceny generują mniej wyświetleń.
- Oferty, które posiadają mniej **recenzji** są bardziej podejrzane.

Przeprowadzona analiza danych wykazała również istotne problemy z jakością dostarczonych zbiorów:

- We wszystkich analizowanych zbiorach zidentyfikowano powtarzający się wzorzec **braków danych na poziomie ok. 20%**. Problem dotyczy kluczowych kolumn, takich jak identyfikatory (*listing_id, date, id*).
- Zbiór ofert charakteryzuje się brakiem danych dotyczących ceny, ilości łóżek, łazienek na poziomie **ok. 50%**. Usunięcie tych rekordów spowoduje utratę połowy zbioru, na co nie możemy pozwolić. Występują także negatywne wartości identyfikatora.
- Kalendarz zawiera duplikaty oraz rekordy z **błędem logicznym** - minimalna liczba nocy jest większa niż maksymalna.
- W zbiorze sesji odnotowano **ok. 94% braków** w kolumnach dotyczących identyfikatora, daty, czy okresu rezerwacji.

Porównując dostępne nam dane, zdecydowanie kluczowym w celu rozwiązania problemu będzie kalendarz z dostępnością i cenami (plik *calendar.csv*). To on umożliwia odczytanie dokładnej zmiany ceny lokalu w czasie, czyli zjawiska będącym sercem całego problemu.

Szczegółowe dane o dostępnych lokalach (*listings.csv*) również mogą okazać się bardzo przydatne. Pozwolą na dokładne porównywanie ofert między sobą i agregowanie ich w grupy w celu wyznaczenia cenowego punktu odniesienia.

Baza klientów i sesji (*sessions.csv*) umożliwi nam zbadanie, które lokale faktycznie są omijane przez użytkowników. Dzięki obecności kolumn takich jak *booking_date* oraz *booking_duration* jesteśmy w stanie sprawdzić, czy “zawyżona” cena skutkuje faktycznym brakiem zainteresowania. Jest to ważne, ponieważ nawet jeśli wszystko wskazuje na to, że oferta jest anomalią, ale jest ona stale wybierana przez klientów to nie można jej jako taką oznaczyć.

Informacje o recenzjach lokali (plik *reviews.csv*), podobnie jak inne szczegółowe dane wspomniane wyżej, ułatwią grupowanie lokali oraz wyznaczenie ceny jakiej spodziewalibyśmy się po danej ofercie.

Struktura dostarczonych danych jest wystarczająca w kontekście rozwiązania problemu, jednak znaczące braki we wszystkich zbiorach nie pozwalają na kontynuację zadania.

Weryfikacja danych - zbiór v1

Statystyki dotyczące ceny:

Średnia	Wartość minimalna	Wartość maksymalna	Odchylenie standardowe
151.84	10.00	9999.00	384.82

Ponownie uwagę zwraca wartość odchylenia, która nie zmieniła się znacząco w porównaniu do poprzedniej wersji zbioru danych. Natomiast nowe dane posiadają znacznie mniej pustych ofert.

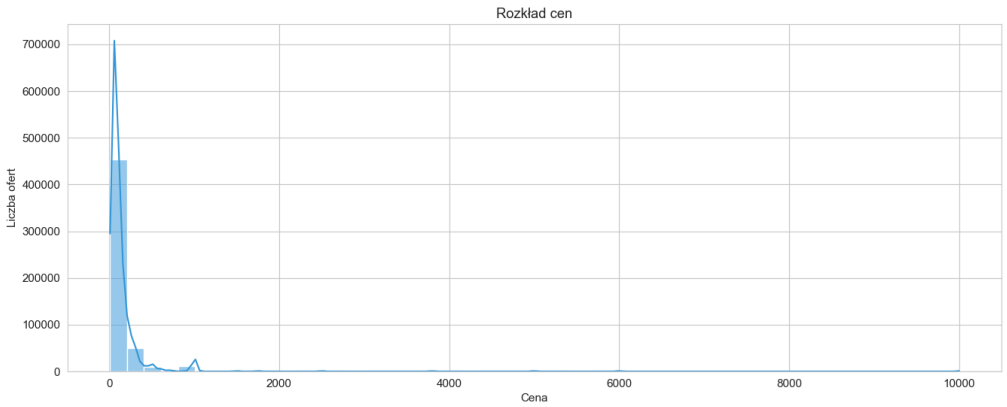

W nowym zbiorze więcej ofert osiąga wysoką liczbę interakcji, prawdopodobnie z powodu mniejszej ilości pustych/uszkodzonych ofert.

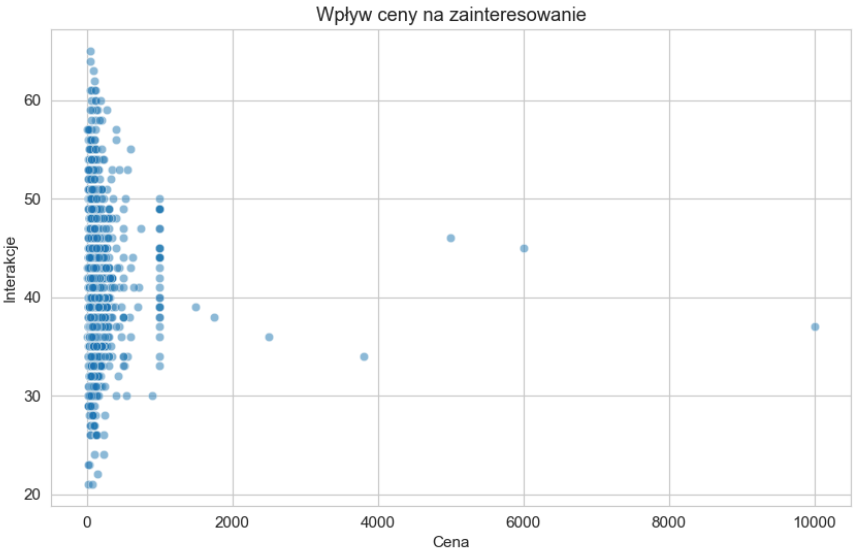

Zależność ceny od typu lokalu oraz dzielnicy nie zmieniła się znacząco w porównaniu do poprzedniego zbioru.

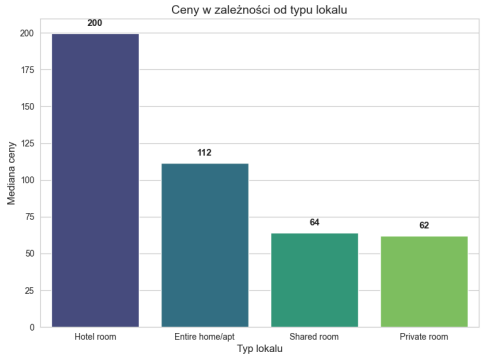

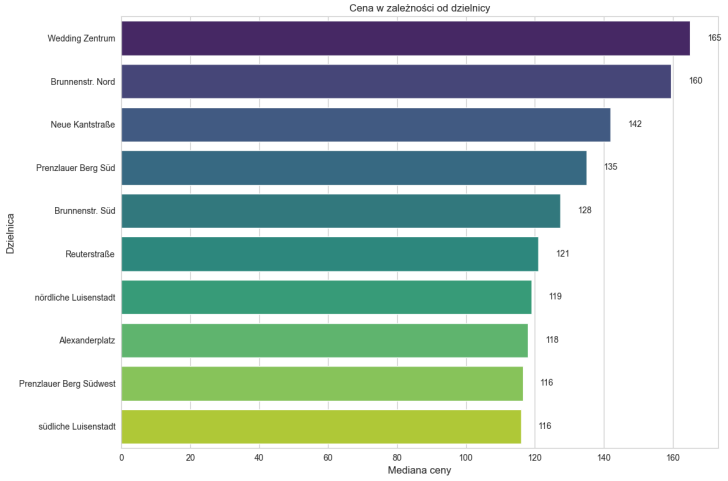

Wykres dostępności w zestawieniu z poprzednim jest bardziej wygładzony, a osiągane wartości dostępności są wyższe - 30% w okresie październik-styczeń oraz 35-45% w pozostałych miesiącach.

Uzupełnienie zbioru danych wpłynęło na korelację zmiennej **oceny** - oferty zidentyfikowane jako podejrzane posiadają niższe oceny w porównaniu do normalnych ofert.

Jakość danych w nowym zbiorze znacząco wzrosła:

- Ze zbioru ofert zostały usunięte ujemne identyfikatory. Braki w cenach, liczbie łóżek/łazienek spadły do **ok. 36%**. Rekordy bez ceny są bezużyteczne, więc należy je odfiltrować. Zidentyfikowano 4 zbędne kolumny, w których występują stałe wartości - również do usunięcia.
- Kalendarz nie zawiera duplikatów. Wciąż występują wiersze z **błędem logicznym** dotyczącym liczby nocy, jednak skala tego problemu jest na tyle mała, że wiersze te mogą zostać usunięte.
- Brak identyfikatorów sesji spadł do akceptowalnego poziomu **ok. 8%**.

Analiza wystarczalności danych do rozwiązania zadania:

- W zbiorze ofert zostanie zastosowana **filtracja** - usunięcie ofert bez kluczowych kolumn, takich jak cena. Sztuczne wstawienie średniej może spowodować, że potencjalnie podejrzane oferty staną się niewidoczne dla modelu. Usunięcie 36% zbioru wciąż pozostawia reprezentatywną część.
- Sesje bez identyfikatorów również zostaną **odfiltrowane** - redukcja zbioru o 8% jest akceptowalna.
- Usunięte zostaną kolumny ze **stałymi wartościami** oraz **błędami logicznymi**.