IUM - Dokumentacja etapu 2

Michał Pędziwiatr, Kacper Siemionek

Treść zadania

“Czasami oferenci zawyżają ceny, aby nikt w danym okresie nie rezerwował u nich noclegów – jakoś musimy to wykrywać, żeby dało się odpowiednio reagować.”

Kontekst

W ramach projektu wcielamy się w rolę analityka pracującego dla portalu Nocarz – serwisu, w którym klienci mogą wyszukać i dokonać rezerwacji noclegu (zapewnianego przez oferentów). Praca na tym stanowisku nie jest łatwa – zadanie dostajemy w formie enigmatycznego opisu i to do nas należy doprecyzowanie szczegółów tak, aby dało się je zrealizować. To oczywiście wymaga zrozumienia problemu, przeanalizowania danych, czasami negocjacji z szefostwem. Poza tym, oprócz przeanalizowania zagadnienia i wytrenowania modeli, musimy przygotować je do wdrożenia produkcyjnego –zakładając, że w przyszłości będą pojawiać się kolejne ich wersje, z którymi będziemy eksperymentować Jak każda szanująca się firma internetowa,

Nocarz zbiera dane dotyczące swojej działalności – są to (analitycy mogą wnioskować o dostęp do tych informacji na potrzeby realizacji zadania):

- szczegółowe dane o dostępnych lokalach,
- recenzje lokali,
- kalendarz z dostępnością i cenami,
- baza klientów i sesji.

Analityczne kryterium sukcesu

Model zostanie uznany za skuteczny, gdy:

- Osiągnie wyniki lepsze o 10 p.p. od **modelu bazowego.**
- **Precyzja** wyniesie 80% lub więcej - ⅘ wysłanych ostrzeżeń trafią do faktycznych oszustów.
- **Czułość** wyniesie 65% lub więcej - model wykryje ponad połowę rzeczywistych przypadków zawyżenia cen.

Modelowanie

Dobór cech

Cechy, które modele biorą pod uwagę:

- *listing_price*: cena oferty
- *number_of_reviews*: liczba recenzji
- *price_vs_neighbourhood*: stosunek ceny oferty do średniej w dzielnicy
- *host_is_superhost_int*: status oferenta
- *availability_365*: dostępność w ciągu roku
- *session_count*: liczba sesji

Zrezygnowano z informacji o cenach znajdujących się w kalendarzu - były one stałe na przestrzeni całego roku, a wykryte oferty z zawyżonymi cenami nie miały tam swojej historii.

Mapa korelacji:

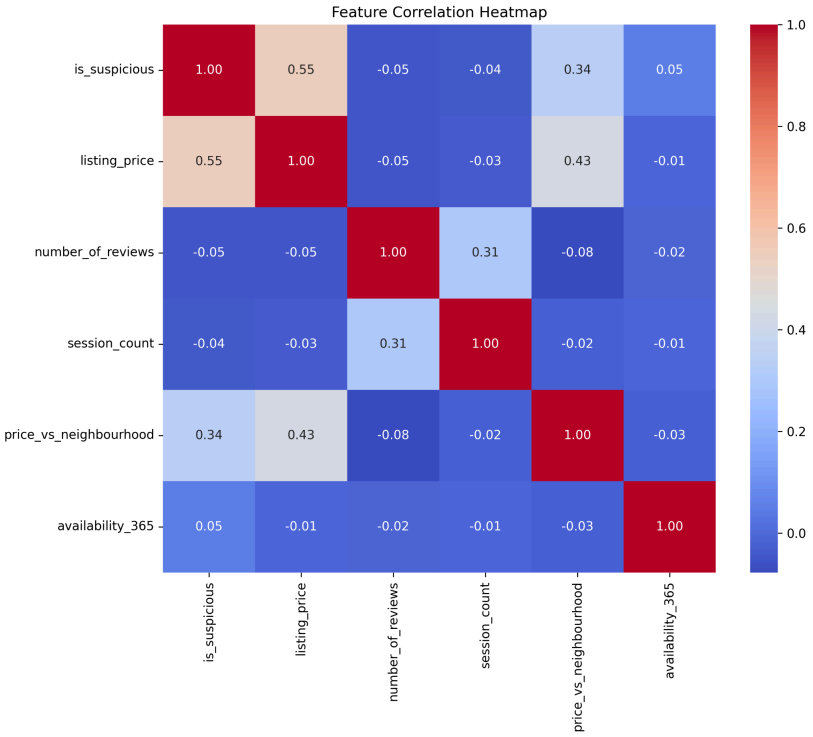

Powyższa wygenerowana macierz korelacji wskazuje na prawidłową strukturę zbioru danych. Niska współzależność cech (poza przekątną) sugeruje brak silnej współliniowości pomiędzy cechami, co znacznie zwiększa stabilność modeli liniowych takich jak nasz model bazowy.

Najbardziej istotne, zaobserwowane zależności:

- *listing_price* i *is_suspicious* (0,55): wskazuje, że cena jest głównym, choć niewystarczającym indykatorem anomalii.
- *price_vs_neighbourhood* i *is_suspicious* (0,34): podobnie jak w pierwszym przypadku, cena odbiegająca od średniej determinuje podejrzany charakter oferty.

Wartość ta sygnalizuje, że model nie powinien patrzeć jedynie na cenę “w próżni”, ale także w kontekście lokalizacji.
- *price_vs_neighbourhood* i *listing_price* (0,43): obie cechy bezpośrednio wiążą się z ceną lokalu. Jest to więc oczywiste, że będą od siebie zależeć w znacznym stopniu.
- *session_count* i *number_of_reviews* (0,31): umiarkowana korelacja potwierdzająca spójność danych. Popularne oferty mają więcej sesji oraz opinii.

Etykietowanie danych

Do wstępnej analizy danych użyto **IsolationForest**. Elementy odstające zostały przefiltrowane zgodnie z celem zadania, odrzucono oferty z:
- ceną poniżej 250$
- liczbą recenzji poniżej 15
- dostępnością w ciągu roku poniżej 150 dni

Dane syntetyczne

W dostarczonych danych wykryto 8 przypadków zawyżonych cen wśród ~1000 ofert. Model trenowany wyłącznie na takich danych miałby tendencję do przeuczenia.

W celu rozwiązania tego problemu, wygenerowano zbiór danych syntetycznych podzielony na trzy rozłączne kategorie, symulujące różne scenariusze rynkowe:
- Oferty standardowe (*safe*): typowe, budżetowe oferty stanowiące główną część rynku. Charakteryzują się stosunkowo niską ceną, adekwatną do średniej w okolicy, wysoką wiarygodnością (duża liczba ocen) oraz częstymi rezerwacjami.
- Oferty podejrzane (*suspicious):* jawnie zawyżone cenowo oferty “widmo”. Cechują się często ekstremalnie wysoką ceną, niską liczbą recenzji oraz wysoką dostępnością przez większość roku kalendarzowego.
- Oferty podchwytliwe *(tricky)*: oferty mogące wyglądać na zawyżone przez ceny zazwyczaj znacznie przewyższające średnią rynkową, w rzeczywistości będąc realnymi, uczciwymi ofertami. W przeciwieństwie do oszustów oferty posiadają bogatszą historię recenzji, a także niższy od nich mnożnik ceny względem okolicy. Kategoria ta służy do weryfikacji, czy model potrafi rozróżnić luksusowe, drogie, realne oferty premium od anomalii cenowych, nie bazując jedynie na prostym progu cenowym.

Warto zaznaczyć, że parametry tych kategorii częściowo się na siebie nakładają. Brak wyraźnej liniowej granicy więc dodatkowo utrudnia modelom zadanie klasyfikacji.

Porównanie modeli

Zbiór dostarczonych oraz syntetycznych danych został podzielony na zbiór treningowy i testowy w proporcjach 80/20. W poniższej tabeli znajdują się wyniki modeli na zbiorze testowym.

Model	Klasa	Precyzja	Czułość
Bazowy	0	0,98	0,99
	1	0,88	0,78
Docelowy	0	0,98	1,00
	1	1,00	0,83

Model docelowy osiągnął lepsze wynikim niż bazowy, tym samym spełniając kryteria analityczne. Jednak ze względu na rozmiar zbioru testowego, prawdziwe różnice pomiędzy modelami pokaże dopiero eksperyment A/B.

Dodatkowo działanie modeli zostało porównane zależnie od % podejrzanych i podchwytliwych ofert występujących w zbiorze.

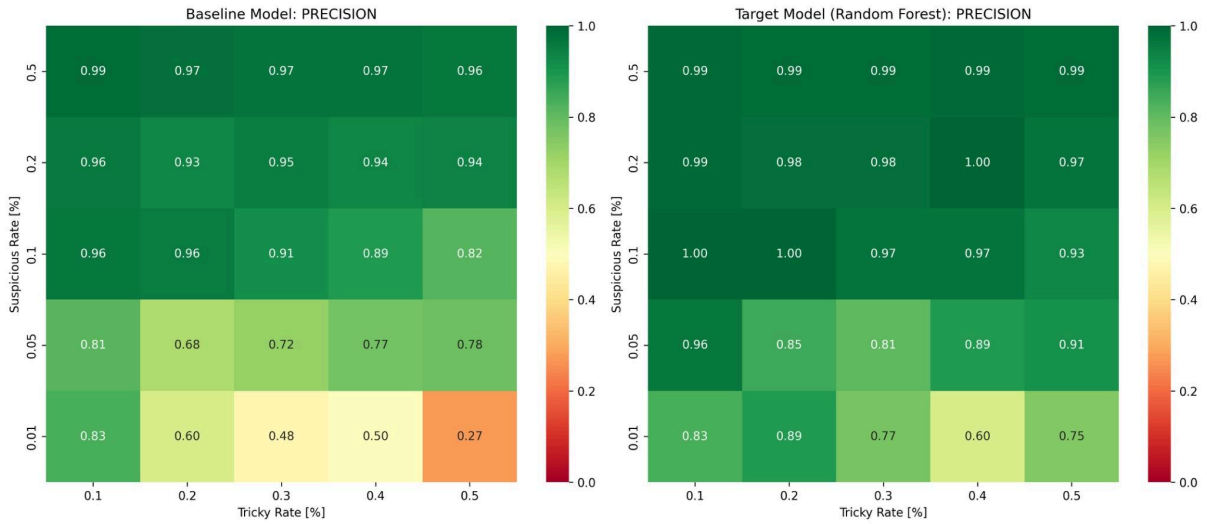

Model bazowy radzi sobie gorzej jeśli chodzi o precyzję, zwłaszcza przy większej ilości podchwytliwych ofert.

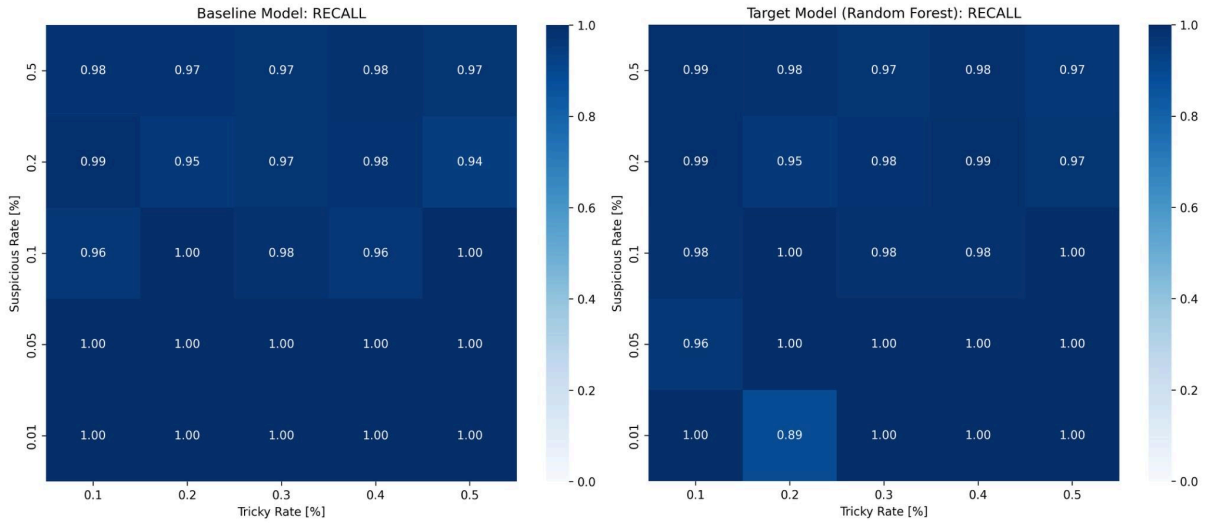

W czułości obu modeli nie widać większych różnic.

Eksperyment A/B

Podczas eksperymentu 10000 wygenerowanych ofert podzielono na dwa zbiory do oceny przez dwa różne modele. Oferty zostały wygenerowane w podobny sposób do danych syntetycznych.

Model	Klasa	Precyzja	Czułość
Bazowy	0	1,00	0,99
	1	0,77	0,98
Docelowy	0	1,00	1,00
	1	0,93	0,99

Ponownie model docelowy zadziałał lepiej, niż bazowy. Pomimo spadku precyzji, wciąż spełnia ona wyznaczone kryteria, podobnie w przypadku czułości, która osiągnęła jeszcze lepszy wynik.